

3. Tutorium Multivariate Verfahren - Clusteranalyse -

Cornelia Gruber
26.05.2020

Institut für Statistik, LMU München

Gliederung

- 1 Idee der Clusteranalyse
- 2 Distanzmaße
- 3 Hierarchische Klassifikationsverfahren
- 4 Nichthierarchische Verfahren

Gliederung

- 1 Idee der Clusteranalyse
- 2 Distanzmaße
- 3 Hierarchische Klassifikationsverfahren
- 4 Nichthierarchische Verfahren

Problemstellung

- Einteilung einer Menge von n Beobachtungen x_1, \dots, x_n in Teilmengen, sogenannte **Cluster**!
- Die Einteilung soll so erfolgen, dass sich
 - die Beobachtungen innerhalb eines Clusters möglichst ähnlich sind
→ Homogenität innerhalb eines Cluster
 - die Cluster untereinander möglichst stark unterscheiden
→ Heterogenität zwischen verschiedenen Cluster
- **Beachte:** Die Klassen/Gruppen sind vorab nicht bekannt und werden gesucht! (im Gegensatz zur Diskriminanzanalyse)
→ unsupervised learning

Datensituation

- Gegeben sind n Beobachtungen mit zugehörigen Merkmalsvektoren $\mathbf{x}_1, \dots, \mathbf{x}_n$, $i = 1, \dots, n$
- $\mathfrak{C} = \{C_1, \dots, C_k\}$ sei eine Partition der Beobachtungen in k Cluster
- Gesucht ist eine disjunkte Zerlegung $\{C_1, \dots, C_k\}$ mit folgenden Eigenschaften:
 - a) $\bigcup_{i=1}^k C_i = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$
 - b) $C_i \cap C_j = \emptyset \forall i \neq j$

Gliederung

- 1 Idee der Clusteranalyse
- 2 Distanzmaße
- 3 Hierarchische Klassifikationsverfahren
- 4 Nichthierarchische Verfahren

Distanz zwischen den Beobachtungen

- Für Distanzmaße $d : \Omega \times \Omega \rightarrow \mathbb{R}$ gilt:
 - $d(x_i, x_j) = d(x_j, x_i)$ (Symmetrie)
 - $d(x_i, x_i) = 0$
 - $d(x_i, x_j) \geq 0, \forall i, j$
 - $d(x_i, x_j) \leq d(x_i, x_r) + d(x_r, x_j)$ (Dreiecksungleichung)
- **Typische Distanzmaße:**
 - $d_q(\mathbf{x}_i, \mathbf{x}_j) = \sqrt[q]{\sum_{l=1}^p (x_{il} - x_{jl})^q}$ (L_q -Metrik)
 - $d_2(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{l=1}^p (x_{il} - x_{jl})^2}$ (euklidische Distanz)
 - $d_1(\mathbf{x}_i, \mathbf{x}_j) = \sum_{l=1}^p |x_{il} - x_{jl}|$ (Manhattan-Metrik)

Gliederung

- 1 Idee der Clusteranalyse
- 2 Distanzmaße
- 3 Hierarchische Klassifikationsverfahren
- 4 Nichthierarchische Verfahren


Grundstruktur

- Konstruktion einer Hierarchie von Partitionen
 $\mathfrak{C} = \{C_1, \dots, C_k\}$. Die Anzahl der Cluster variiert dabei von 1 bis zur Anzahl der Beobachtungen!
- **Agglomerative** Verfahren: zu Beginn bildet jede Beobachtung ein eigenes Cluster
- **Divisive** Verfahren: zu Beginn ein großes Cluster, das alle Beobachtungen enthält
- **Merke:** Die Hierarchie enthält das Klassifikationsergebnis für jede mögliche Anzahl an Clustern (beliebig wählbar)
- Hierarchischen Klassifikationen erfordern Definition der
 - Distanz zwischen Beobachtungen (vgl. Metriken Folie 7)
 - Distanz zwischen Clustern → **Linkage**


Linkage-Methoden

- C_r, C_s : Cluster
- **Single Linkage:** $D(C_r, C_s) = \min_{x_i \in C_r, x_j \in C_s} d(x_i, x_j)$
- **Complete Linkage:** $D(C_r, C_s) = \max_{x_i \in C_r, x_j \in C_s} d(x_i, x_j)$
- **Average Linkage:** $D(C_r, C_s) = \frac{1}{|C_r||C_s|} \sum_{x_i \in C_r, x_j \in C_s} d(x_i, x_j)$
- **Zentroid-Verfahren:** $D(C_r, C_s) = \|\bar{x}_r - \bar{x}_s\|^2$
- **Ward:** $D(C_r, C_s) = \frac{|C_r||C_s|}{|C_r|+|C_s|} \|\bar{x}_r - \bar{x}_s\|^2,$
 \bar{x}_r, \bar{x}_s : Mittelwert der Beobachtungen in Cluster C_r, C_s


Single Linkage




Complete Linkage



Average Linkage



Centroid Linkage



Agglomerative Verfahren

- **Algorithmus:**

- ① **Start:** Feinste Partition: Jede Beobachtung bildet ein eigenes Cluster: $\mathfrak{C} = \{\{x_1\}, \dots, \{x_n\}\}$
 - ② Vereinige im ν -ten Schritt zwei Cluster C_r, C_s mit dem kleinsten Abstand und berechne den Homogenitätsindex:
$$h_\nu = \min_{r \neq s} D(C_r, C_s).$$
 - ③ Wiederhole 2. bis ein großes Cluster entsteht, das alle Beobachtungen enthält: $\mathfrak{C} = \{x_1, \dots, x_n\}$
- Die Distanzen der Beobachtungen werden durch die festgelegte *Metrik*, die Distanzen der Cluster durch die festgelegte *Linkage-Methode* bestimmt!

Divisive Verfahren

- **Algorithmus:**


- ① Bestimme Cluster mit dem größten Durchmesser
(Durchmesser = größte Distanz zwischen zwei Objekten im Cluster)
- ② Splitte zunächst das Objekt vom Cluster ab, das zu den anderen Objekten im Cluster die größte mittlere Unähnlichkeit aufweist. Dieses Objekt initialisiert die "Splittergruppe"
- ③ Ordne Objekte aus dem geteilten Cluster der Splittergruppe zu, wenn sie dieser ähnlicher sind als dem "alten" Cluster

- **Beachte:** Pro Schritt gibt es $O(2^n)$ Möglichkeiten zu splitten
⇒ Für großes n ist agglomerativ einfacher ($O(n^2)$) Möglichkeiten zum Zusammenfassen)!

Dendrogramm

- Graphische Darstellung eines hierarchischen Clusterings
- y -Achse: Homogenitätsmaß h
→ je kleiner h , desto homogener ist der Cluster!
- Sukzessives Zusammenfassen bzw. Aufteilen erkennbar

Dendrogramm



Gliederung

- 1 Idee der Clusteranalyse
- 2 Distanzmaße
- 3 Hierarchische Klassifikationsverfahren
- 4 Nichthierarchische Verfahren

Grundprinzip

- **Ziel:** Finde die Partition $\mathfrak{C} = \{C_1, \dots, C_k\}$ bestehend aus k Clustern, die bezüglich eines Gütekriteriums optimal ist!
- Man betrachtet für jede Partition ein **Optimalitätskriterium**, das die Heterogenität erfasst:

$$H(\mathfrak{C}_{opt}) = \min_{\mathfrak{C}} H(\mathfrak{C})$$

- **Austauschverfahren:**

- ① Wähle eine zufällige Ausgangspartition aus k Beobachtungen
- ② Prüfe in der Partition \mathfrak{C}^{alt} , ob die Zuordnung jeweils einer Beobachtung in einen anderen Cluster, das betrachtete Optimalitätskriterium minimiert.

- **Beachte:**

- Die Anzahl der Cluster k muss vom Anwender fest vorgegeben werden!
- Je nach gewählter Ausgangspartition, können unterschiedliche Cluster entstehen.

Optimalitätskriterien

- ① Varianzkriterium (= k-means clustering)

$$H(\mathfrak{C}) = \sum_{r=1}^k \sum_{x_i \in C_r} \|\mathbf{x}_i - \bar{\mathbf{x}}_r\|^2$$

- ② Determinantenkriterium

$$H(\mathfrak{C}) = |\mathbf{W}(\mathfrak{C})| \xrightarrow{\mathfrak{C}} \min$$

- ③ Verallgemeinertes Determinantenkriterium

$$H(\mathfrak{C}) = \sum_{r=1}^k n_r \log \left(\frac{1}{n_r} \mathbf{W}(\mathfrak{C}_r) \right) \xrightarrow{\mathfrak{C}} \min$$

Merke: Die Determinante entspricht einer verallgemeinerten Varianzmatrix!

k-Means Clustering

Vorgehen:

- ① Wähle zufällig k Beobachtungen bzw. die zugehörigen Merkmalsvektoren \mathbf{x} als Clusterschwerpunkte $Z_r, r = 1, \dots, k$. Die Clusteranzahl k ist fest!
- ② Ordne jede Beobachtung dem Clusterzentrum zu, zu dem die geringste Distanz $d_r, r = 1, \dots, k$ besteht.
- ③ Berechne neue Clusterschwerpunkte $Z_r, r = 1, \dots, k$ als Mittelwertsvektoren der Merkmalsvektoren der Beobachtungen im Cluster!
- ④ Wiederhole 2. und 3. bis zur Konvergenz.

siehe Animation:

https://de.wikipedia.org/wiki/K-Means-Algorithmus#/media/Datei:K-means_convergence.gif