

Tutorium 3

Montag, 25. Mai 2020 15:37

- 1 a) Warum ist es sinnvoll, die Variablen zu standardisieren (zentrieren und skalieren), oder zu normalisieren (Maximum abziehen und durch Spannweite/Range teilen) bevor man die euklidische Distanzmatrix berechnet?


Standardisieren: $X^* = \frac{x - \bar{x}}{\sqrt{\text{Var}(x)}}$

→ danach $E(X^*) = 0$ & $\text{Var}(X^*) = 1$

Normalisieren: $X^{**} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$


→ behält Form der Verteilung

→ $X^{**} \in [0, 1]$



2a)

- a) Geben Sie $C^{(0)}$ an und berechnen Sie die neuen Schwerpunkte für jede Klasse.



$$C^0 = \{ \{u_1\}, \{u_4, u_2, u_3, u_5\} \}$$

neue Schwerpunkte: $x_1^{(1)} = \begin{pmatrix} 2 \\ 10 \end{pmatrix}, x_2^{(1)} = \begin{pmatrix} \frac{2+8+5+7}{4} \\ \frac{5+4+8+3}{4} \end{pmatrix} = \begin{pmatrix} 5,5 \\ 5,5 \end{pmatrix}$

2b)

b) Führen Sie das k-means Clusterverfahren zu Ende.

$$D^{(1)} = \begin{pmatrix} \min & 0 & 25 & 72 & 13 & 50 \\ & 32,5 & 12,5 & 8,5 & 6,5 & 2,5 \end{pmatrix} \leftarrow x_1 \text{ Distanz zu Schwerpunkt 1}$$

$\uparrow \quad \uparrow \quad \uparrow \quad \uparrow \quad \uparrow$

$$\begin{matrix} u_1 & u_2 & u_3 & u_4 & u_5 \end{matrix} \leftarrow x_2 \text{ Distanz zu Schwerpunkt 2}$$

$$d(u_1, x_2^{(1)}) = (2 - 5,5)^2 + (10 - 5,5)^2 = 12,25 + 20,25 = 32,5$$


$$C^{(1)} = \{ \{u_1, 3\}, \{u_2, u_3, u_4, u_5\} \} = C^{(0)}$$

neue Partition

= alte Partition \rightarrow Konvergenz

3b) i)

i) Lesen Sie sich die Hilfe zu der Funktion `mclustModelNames` aus dem Paket `mclust` durch und ordnen Sie den unten stehenden Abbildungen jeweils ein Modell zu.




1: EEE ellipsoidal, equal volume, shape

2. VII diagonal, varying volume, shape


3. VUV ellipsoidal, varying volume, shape, & orientation

4. EII spherical, equal volume (\rightarrow ähnliche Ergebnisse wie k-means)

spherical: keine Korrelationen unabhängige Variablen
gleiche Varianzen der Variablen



diagonal: streckung in X & Y Richtung \rightarrow unterschiedliche Varianzen
 \rightarrow keine Korrelationen



→ keine Korrelationen
(→ unabhängige Variablen)

ellipsoidal: Streckung in beliebige Richtung → Korrelationen möglich
→ unterschiedliche Varianzen

- ii) Beschreiben Sie anhand der Kovarianzmatrix, wie Distribution, Volume, Shape und Orientation ausgeprägt sind.

$$\begin{array}{ll}
 \text{spherical} & \sum_i = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \dots & 0 \\ 0 & \dots & \sigma_n^2 \end{pmatrix} \\
 \text{diagonal} & \sum_i = \begin{pmatrix} \sigma_1^2 & 0 & \dots \\ 0 & \sigma_2^2 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix} \\
 \text{ellipsoidal} & \sum_i = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots \\ \sigma_{21} & \sigma_2^2 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}
 \end{array}
 \quad \left. \right\} \text{Kovarianz für ein Cluster}$$

$$\sum_k = \lambda_k D_k A_k D_k^\top \rightarrow \text{Zerlegung der Kovarianzmatrix}$$

λ_k : Volumen

A_k : Diagonalmatrix mit Determinante 1 → shape

D_k : Orthogonalmatrix → orientation