

# **Multivariate Verfahren**

## Trees und Random Forests

Annika Hoyer

Sommersemester 2020

# Trees und Random Forests - Inhalt

Classification and Regression Trees

Conditional Inference Trees

Random Forests

# **Classification and Regression Trees**

# Ausgangssituation

- ▶ Beobachtung von Merkmalsvektoren  $\mathbf{x}_1, \dots, \mathbf{x}_n$  der Objekte  $a_1, \dots, a_n$
  - ▶ Ziel: von Merkmalsvektoren auf Zielvariable  $Y_1, \dots, Y_n$  schließen
1. Zufallsvariable  $Y$  kann **stetig** sein  
→ Regressionsproblem
  2. Zufallsvariable  $Y$  kann **binär** oder **kategorial** sein  
→ Klassifikationsproblem

Im Fall eines Klassifikationsproblems ist die Fragestellung analog zur Diskriminanzanalyse.

# Trees - Motivation

- ▶ Populärste Methode: Classification and Regression Trees (**CART**)
- ▶ Einführung von Breiman et al. (1984)
- ▶ Idee: Teile  $p$ -dimensionalen Merkmalsraum durch Splitten sukzessive in Teilmengen des Merkmalsraums auf  
→ "Rekursives Partitionieren"
- ▶ Bilde Teilmengen des Merkmalsraums so, dass sie bezüglich der Zielvariable möglichst **homogen** sind

# CART - Grundprinzip

- ▶ Betrachte in jedem Schritt **binäre** Splits, d.h. in jedem Schritt wird eine (bereits gebildete) Teilmenge weiter in genau zwei Teile aufgeteilt
- ▶ Betrachte in jedem Schritt **genau eine** Variable, die den neuen Split bestimmt
- ▶ Resultat: **disjunkte** Zerlegung des Merkmalsraums, die in einer Baumstruktur dargestellt werden kann

## Beispiel: Studienanfänger Wirtschaftswissenschaften

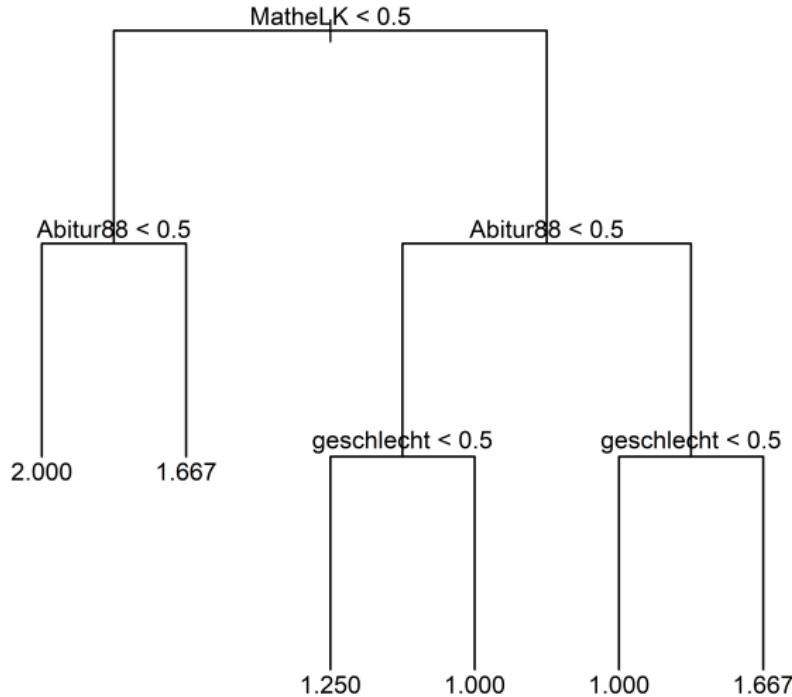
- ▶ Test zur Mittelstufenalgebra (26 Fragen) im Wintersemester 1988/89 bei Studienanfängern der Wirtschaftswissenschaften an der FU Berlin
- ▶ Variablen:
  - ▶ Geschlecht: w/m (1/0)
  - ▶ Besuch Leistungskurs Mathe: j/n (1/0)
  - ▶ Abitur im Jahr 1988: j/n (1/0)
  - ▶ Abinote Mathematik
  - ▶ Anzahl der im Test richtig gelösten Aufgaben
  - ▶ Gruppe 1: mindestens 14 Punkte erreicht → Test bestanden
  - ▶ Gruppe 2: weniger als 14 Punkte → Test nicht bestanden

# Beispiel: Studienanfänger Wirtschaftswissenschaften

Ergebnisse der Studienanfänger bei dem Mathetest

Geschlecht	MatheLK	MatheNote	Abitur88	Gruppe
0	0	3	0	2
0	0	4	0	2
0	0	4	0	2
0	0	4	0	2
1	0	3	0	2
...	...	...	...	...

# Beispiel: Studienanfänger Wirtschaftswissenschaften



# Trees - Notation

1. Wurzelknoten (root nodes): oberster Knoten
2. Entscheidungsknoten (children nodes): Beantwortung einer Frage mit ja/nein. Wird die Frage mit ja beantwortet, geht man zum linken Ast des Baumes zum nächsten Knoten, andernfalls zum rechten Ast.
3. Endknoten / Blätter (terminal nodes): unterster Knoten

## Beispiel: Studienanfänger Wirtschaftswissenschaften

1. MatheLK < 0.5? bzw. Hat der Studierende den Mathematik-Leistungskurs nicht besucht?  
→ Beantwortung mit "nein": Weiter zum Knoten im rechten Ast
2. Abitur88 < 0.5? bzw. Hat der Studierende sein Abitur nicht 1988 gemacht?  
→ Beantwortung mit "nein": Weiter zum Knoten im rechten Ast
3. Geschlecht < 0.5? bzw. Ist der Studierende männlich?  
→ Beantwortung mit "j": Weiter zum linken Ast mit Endknoten  
→ Zugeordnete Zahl: 1 → Gruppe 1

# CART - Binäre Splits

- ▶ Art des Splits hängt vom Skalenniveau der Merkmale  $x_1, \dots, x_p$  ab
- ▶ Aufteilung eines Knotens  $A$  in die Knoten  $A_1$  und  $A_2$  hat die folgende Form:
  1. Falls  $x_j$  metrisch oder ordinal, bildet man

$$A_1 = A \cap \{x_j \leq c_j\} \quad \text{und} \quad A_2 = A \cap \{x_j > c_j\},$$

mit Splitpunkt  $c_j$  aus dem Wertebereich  $S_j$  von  $x_j$

2. Falls  $x_j$  nominal, bildet man

$$A_1 = A \cap B \quad \text{und} \quad A_2 = A \cap \overline{B},$$

wobei  $B \subset S_j$  und  $\overline{B} = S_j \setminus B$ .

## CART - Klassifikationsregel (2-Klassen-Fall)

- ▶ Gegeben: Baum mit  $Q$  Endknoten  $A_1, \dots, A_Q$
- ▶ Geschätzte Wahrscheinlichkeiten in jedem Knoten:

$$\hat{p}_{q1} = \frac{1}{n_q} \sum_{a_i \in A_q} I(Y_i = 1) \quad \text{und}$$

$$\hat{p}_{q2} = \frac{1}{n_q} \sum_{a_i \in A_q} I(Y_i = 2), \quad q = 1, \dots, Q.$$

Ordne alle Objekte  $a_i \in A_q$  in Klasse 1 zu, falls  $\hat{p}_{q1} > \hat{p}_{q2}$  (oder äquivalent falls  $\hat{p}_{q1} > 0.5$ ), ansonsten zu Klasse 2.

## Beispiel: Studienanfänger Wirtschaftswissenschaften

- ▶  $p_{11}$ : Wahrscheinlichkeit im Wurzelknoten zu Gruppe 1 zu gehören
- ▶  $p_{11} > 0.5$ : Gruppe 1
- ▶  $p_{11} < 0.5$ : Gruppe 2
- ▶  $p_{11} = 0.5$ : zufällige Zuteilung
- ▶  $\hat{p}_{11} = 0.45 \rightarrow$  ordne zufällig ausgewählten Studierenden Gruppe 2 zu

# Unreinheit/Unsicherheit der Entscheidung

- ▶ Je näher  $p_{q1}$  an 0.5, desto fehlerhafter Entscheidung
- ▶ Quantifizierung durch Maßzahl?
- ▶ Betrachte Zufallsvariable  $Y$ :

$$Y = \begin{cases} 1 & \text{falls der Studierende zur Gruppe 1 gehört} \\ 0 & \text{falls der Studierende zur Gruppe 2 gehört} \end{cases}$$

- ▶  $Y$  ist bernoulliverteilt mit Parameter  $p_{q1}$  und Varianz  $p_{q1}(1 - p_{q1})$
- Je näher  $p_{q1}$  an 0.5, umso größer Varianz
- Varianz minimal, wenn  $p_{q1} 0$  oder  $1$  ist

# CART - Splitkriterien (2-Klassen-Fall)

- ▶ Betrachte in jedem Schritt "Unreinheit" der bereits gebildeten Knoten
- ▶ Sei  $p_{q1}$  der Anteil von Klasse 1 im Knoten  $A_q$ , so kann man folgende Maße betrachten:

1. Fehlklassifikation:

$$F(A_q) = 1 - \max(p_{q1}, 1 - p_{q1})$$

2. Gini Index:

$$G(A_q) = 2 p_{q1}(1 - p_{q1})$$

3. Entropy:

$$E(A_q) = -p_{q1} \log(p_{q1}) - (1 - p_{q1}) \log(1 - p_{q1})$$

## Beispiel: Studienanfänger Wirtschaftswissenschaften

- ▶ Wurzelknoten:  $p_{11} = 0.45$
- $G(A_1) = 2 \cdot 0.45(1 - 0.45) = 0.495$
- Unreinheit des Wurzelknotens groß, da beide Gruppe nahezu gleich häufig in der Population vertreten
- ▶ Zerlegung in Knoten  $A_2$ : 1 von 9 Studierenden, die keinen MatheLK besucht hat, sind in Gruppe 1 →  $p_{21} = \frac{1}{9}$
- $G(A_2) = 2 \cdot \frac{1}{9} \left(1 - \frac{1}{9}\right) = 0.1975$
- ▶ Zerlegung in Knoten  $A_3$ : 8 von 11 Studierenden, die einen MatheLK besucht haben, sind in Gruppe 1 →  $p_{31} = \frac{8}{11}$
- $G(A_3) = 2 \cdot \frac{8}{11} \left(1 - \frac{8}{11}\right) = 0.3967$
- ▶ Unreinheit in den Knoten  $A_2$  und  $A_3$  kleiner als im Wurzelknoten
- Aufteilung in Teilpopulationen, die hinsichtlich des Merkmals "bestanden" homogener sind

# CART - Baumkonstruktion

- ▶ Wähle in jedem Schritt der Baumkonstruktion Knoten, Variable  $x_j$  und Splitpunkt  $c_j$  aus, die Unreinheit in neuen Knoten minimiert
- ▶ Teilt man Knoten  $A_1$  in Knoten  $A_2$  und  $A_3$  (unter Verwendung des Gini Index), so minimiert man

$$G(A_2, A_3) = n_2 G(A_2) + n_3 G(A_3),$$

wobei  $n_2$  und  $n_3$  Anzahl der Beobachtungen in den beiden neuen Knoten

# Beispiel: Studienanfänger Wirtschaftswissenschaften

- MatheLK:

$$\begin{aligned}G(A_2, A_3) &= n_2 G(A_2) + n_3 G(A_3) \\&= 1 \cdot 0.1975 + 8 \cdot 0.3967 \\&= 3.3711\end{aligned}$$

Merkmal	$G(A_2, A_3)$
Geschlecht	4.9
MatheLK	3.3711
Abitur88	4.4514

→ Start mit MatheLK, dann Abitur88, dann Geschlecht

# CART - Pruning

- ▶ (theoretische) Fortsetzung der Baumkonstruktion bis alle Knoten **vollkommen homogen**
- sehr starke Gefahr des Overfitting

Definiere ein geeignetes Stopkriterium, um die Größe des Baumes (d.h. die Anzahl an Splits) zu kontrollieren ("Pruning").

Mögliche Stopkriterien:

- ▶ minimale Anzahl an Beobachtungen pro Blatt (Endknoten)
- ▶ minimale Verbesserung des Unreinheitsmaßes
- ▶ maximale Anzahl an Stufen/Levels des Baumes

# Cost-Complexity Pruning

- ▶ Starte bei Blättern des Baumes und fasse diejenigen Knoten wieder zusammen, die zur kleinsten Verschlechterung der Klassifikationsgenauigkeit führen
- Genestete Sequenz an Unterbäumen, die im Bezug auf die Klassifikationsgenauigkeit für eine gegebene Baumgröße optimal sind
- ▶ Bestimme aus Sequenz den optimalen Baum durch Minimierung einer Kosten-Komplexitäts-Funktion
- Führt zu Kompromiss zwischen Klassifikationsgenauigkeit und Baumgröße

# Kosten-Komplexitäts-Funktion

- ▶ Bestimme optimalen Baum durch Minimierung der Funktion

$$R_\alpha(T) = R(T) + \alpha |T|.$$

- ▶  $R(T)$  Unreinheit des Baumes, z.B. über den Gini Index
- ▶  $|T|$  Größe des Baumes, d.h. Anzahl an Blättern
- ▶  $\alpha$  Tuning-Parameter, der die Baumgröße steuert
- Bestimmung von  $\alpha$  durch Resampling-Methoden, z.B. durch Kreuzvalidierung

# $k$ -fache Kreuzvalidierung

1. Setze  $\alpha$  fest
2. Teile den Datensatz zufällig in  $k$  gleich große Teile auf
3. Für  $k = 1, \dots, K$ :
  - ▶ Fitte den Baum  $T_k$  auf allen Daten außer Teil  $k$
  - ▶ Berechne das Kostenkomplexitätskriterium  $R_\alpha(T_k)$  auf Teil  $k$
4. Berechne das Gesamtkriterium  $R_\alpha(T) = \frac{1}{k} \sum_{r=1}^k R_\alpha(T_k)$
5. Wiederhole die Schritte 1 bis 4 für verschiedene Werte von  $\alpha$
6. Bestimme den Wert von  $\alpha$ , der das Gesamtkriterium in Schritt 4 minimiert

## Trees - Variablenelektion

- ▶ Durch Pruning kommen möglicherweise nicht alle Merkmale  $x_1, \dots, x_p$  im resultierenden Baum vor
- ▶ Baum selektiert automatisch die **informativen** Variablen und schließt gleichzeitig die nicht informativen Variablen für die Klassifikation aus
- ▶ Problem: Variablen mit einer großen Anzahl an Ausprägungen (möglichen Splits) werden bevorzugt ausgewählt.
- kann zu einer Verzerrung in der Variablenelektion führen

## Mögliche Alternative

- ▶ Devianz eines Knotens  $A_q$ :

$$D_q = -2[n_{1q} \ln(p_{1q}) + (n_q - n_{1q}) \ln(1 - p_{1q})]$$

mit

- ▶  $n_q$ : Anzahl der Beobachtungen im Knoten  $A_q$
  - ▶  $n_{1q}$ : Anzahl der Beobachtungen im Knoten  $A_q$ , die zu Gruppe 1 gehören
  - ▶  $p_{1q}$ : Wahrscheinlichkeit, dass Beobachtung in Knoten  $A_q$  zu Gruppe 1 gehört
  - ▶ Schätze  $p_{1q} = n_{1q}/n_q$
- Geschätzte Devianz:

$$\hat{D}_q = -2[n_{1q} \ln(n_{1q}/n_q) + (n_q - n_{1q}) \ln(n_{1q}/n_q)]$$

- Wähle Merkmal zur Verzweigung, bei dem Verminderung der Devianz

$$\hat{D}_1 - \hat{D}_2 - \hat{D}_3$$

am größten ist

## Beispiel: Studienanfänger Wirtschaftswissenschaften

- MatheLK: Wurzelknoten mit  $n_q = 20$  und  $n_{1q} = 9$

$$\hat{D}_1 = -2[9 \ln(9/20) + (20 - 9) \ln(1 - 9/20)] = 27.53$$

- 9 Studierende haben keinen MatheLK besucht, davon einer in Gruppe 1

$$\hat{D}_2 = -2[1 \ln(1/9) + (9 - 1) \ln(1 - 1/9)] = 6.28$$

- 11 Studierende haben MatheLK besucht, davon 8 in Gruppe 1

$$\hat{D}_3 = -2[8 \ln(8/11) + (11 - 8) \ln(1 - 8/11)] = 12.89$$

- Verminderung der Devianz:

$$\hat{D}_1 - \hat{D}_2 - \hat{D}_3 = 27.53 - 6.28 - 12.89 = 8.36$$

- Verminderung bei Geschlecht: 0.21

- Verminderung bei Abitur88: 0.03

# Conditional Inference Trees

# Conditional Inference Trees

- ▶ CART selektieren Variablen, jedoch steht kein Konzept der statistischen Signifikanz dahinter
- ▶ Problem adressiert durch Konzept der Conditional Inference Trees (Hothorn et al, 2006)
- ▶ Grundidee: Verwende  $p$ -Werte von Signifikanztests zur Selektion der Splits

# Conditional Inference Trees - Konzept

- ▶ Teste in jedem Schritt der Baumkonstruktion (in jedem Knoten) die globale Nullhypothese  $H_0$  der Unabhängigkeit zwischen der Zielvariable  $Y$  und allen Merkmalen  $x_1, \dots, x_p$
- ▶ Annahme: Verteilung der Zielvariable  $D(Y)$  gegeben die Merkmale kann über Baumstruktur beschrieben werden, d.h.

$$D(Y|x_1, \dots, x_p) = D(Y|\text{tr}(x_1, \dots, x_p))$$

- ▶ Notwendig: Annahme über bedingte Verteilung der Zielvariable

# Conditional Inference Trees - Algorithmus

1. Teste in jedem bereits gebildeten Knoten die Nullhypothese

$$H_0 = \bigcap_{j=1}^p H_0^j, \quad \text{wobei} \quad H_0^j : D(Y|x_j) = D(Y)$$

- Falls  $H_0$  nicht abgelehnt wird, wird der jeweilige Knoten als Endknoten deklariert
- 2. Selektiere die Variable  $x_j^*$  mit der stärksten Assoziation
- 3. Bestimme zur Variable  $x_j^*$  den optimalen Splitpunkt  $c_j^*$  und führe den Split durch
- 4. Wiederhole die Schritte 1 bis 3 bis alle Knoten als Endknoten deklariert wurden

## Conditional Inference Trees - Details

- ▶ In Schritt 2 des Algorithmus werden *p*-Werte der Tests verwendet
- unverzerrte Variablenelektion
- ▶ Approximation der wahren Verteilung der Teststatistiken nach Konzept basierend auf Permutationstests (Strasser und Weber, 1999)
- ▶ Da in jedem Schritt  $p$  Hypothesen gleichzeitig getestet werden, ist eine Adjustierung des Signifikanzniveaus  $\alpha$  notwendig, z.B. über Bonferroni-Korrektur

# **Random Forests**

# Random Forests - Motivation

- ▶ Nachteil von Bäumen: hohe Instabilität, d.h. kleine Änderungen in Daten können zu sehr unterschiedlichen Bäumen führen
- Zwar einfach interpretierbar, aber für verlässliche Vorhersage oft ungeeignet
- Stabilisiere die Ergebnisse einzelner Bäume durch Betrachtung eines **Ensembles vieler Bäume**
- random forests

# Random Forests - Grundprinzip

- ▶ Basieren auf Konzept des **Bagging** (Bootstrap Aggregating)
- ▶ Betrachtung von  $B$  Bootstrap-Stichproben (Ziehen mit Zurücklegen), auf denen jeweils ein Baum gefittet wird
- ▶ Klassifikation über Aggregation der Ergebnisse der  $B$  Bäume

# Random Forests - Algorithmus

1. Ziehe Bootstrap Stichprobe aus dem originalen Datensatz
2. Fitte Baum (CART oder Conditional Inference Tree), wobei bei jedem Split nur  $m < p$  zufällig ausgewählte Merkmale zur Auswahl herangezogen werden  
→ Verringerung der Korrelation zwischen den Bäumen
3. Wiederhole die Schritte 1 und 2  $B$  mal.

# Random Forests - Klassifikationsregel (2-Klassen-Fall)

- ▶ Algorithmus liefert geschätzte Wahrscheinlichkeiten  $\hat{p}_{i1}^b$  und  $\hat{p}_{i2}^b$  für alle Beobachtungen  $i = 1, \dots, n$  und alle Wiederholungen  $b = 1, \dots, B$

## Averaging

Berechne die mittleren Wahrscheinlichkeiten

$$\hat{p}_{i1} = \frac{1}{B} \sum_{b=1}^B \hat{p}_{i1}^b \quad \text{und} \quad \hat{p}_{i2} = \frac{1}{B} \sum_{b=1}^B \hat{p}_{i2}^b.$$

Ordne das Objekt  $a_i$  in Klasse 1 zu, falls  $\hat{p}_{i1} > \hat{p}_{i2}$ , ansonsten zu Klasse 2.

# Random Forests - Klassifikationsregel (2-Klassen-Fall)

- ▶ Algorithmus liefert geschätzte Wahrscheinlichkeiten  $\hat{p}_{i1}^b$  und  $\hat{p}_{i2}^b$  für alle Beobachtungen  $i = 1, \dots, n$  und alle Wiederholungen  $b = 1, \dots, B$

## Majority Vote

Bestimme die Klassifikation für alle B Wiederholungen.

Ordne das Objekt  $a_i$  in Klasse 1 zu, falls  $a_i$  häufiger in Klasse 1 zugeordnet wurde, ansonsten zu Klasse 2.

## Random Forests - Variablenwichtigkeit

- ▶ Einzelne Bäume: einfach interpretierbar
- ▶ Random forests: nicht einfach interpretierbar
- Einfluss einzelner Merkmale schwierig zu evaluieren
- ▶ Lösung: Variablenwichtigkeitsmaße (basierend auf Permutationen der Daten oder basierend auf Splitkriterium)

# Permutation-Variablenwichtigkeit

- ▶  $i_b = 1, \dots, n_b$ ,  $b = 1, \dots, B$ : Beobachtungen der Bootstrap Stichproben
- ▶  $i_{\bar{b}} = 1, \dots, n_{\bar{b}}$ : Beobachtungen, die jeweils nicht zur Baumkonstruktion verwendet wurden ("out of bag" Beobachtungen)
- ▶ Bestimme für jeden der  $B$  Bäume und jede Variable  $x_j$  die Differenz der Klassifikationsgenauigkeit

$$VI^b(x_j) = \frac{\sum_{i_{\bar{b}}=1}^{n_{\bar{b}}} I(Y_{i_{\bar{b}}} = \hat{Y}_{i_{\bar{b}}}^b)}{n_{\bar{b}}} - \frac{\sum_{i_{\bar{b}}=1}^{n_{\bar{b}}} I(Y_{i_{\bar{b}}} = \hat{Y}_{i_{\bar{b}},j}^b)}{n_{\bar{b}}}.$$

- ▶  $\hat{Y}_{i_{\bar{b}}}^b$  geschätzte Klasse auf der originalen Bootstrap Stichprobe
- ▶  $\hat{Y}_{i_{\bar{b}},j}^b$  geschätzte Klasse nach Permutation von Variable  $x_j$

# Permutation-Variablenwichtigkeit

- ▶ Berechne jeweils die mittlere Differenz

$$VI(x_j) = \frac{1}{B} \sum_{b=1}^B VI^b(x_j), \quad j = 1, \dots, p,$$

als Maß für die Variablenwichtigkeit

- ▶ **Beachte:**  $VI^b(x_j) = 0$  falls  $x_j$  im  $b$ -ten Baum nicht vorkommt